Reconstruction de Rang Bas et Compression d'Images par Décomposition en Valeurs Singulières (SVD)

Bouchakal Yanis

September 2026

Étudiant en Licence Informatique

1 Introduction

En algèbre linéaire appliquée, la réduction de dimensionnalité est un enjeu fondamental pour le traitement de données massives et la tôle-filtrage du bruit. Ce projet explore la **Décomposition en Valeurs Singulières (SVD)** appliquée à la compression d'images matricielles. L'objectif est d'étudier théoriquement et numériquement l'approximation d'une matrice par une sous-matrice de bas rang, tout en analysant l'erreur de restitution selon le **Théorème d'Eckart-Young-Mirsky**.

2 Modélisation Théorique et Fondements Mathématiques

2.1 La Décomposition en Valeurs Singulières (SVD)

Soit $A \in R^{m\times n}$ une matrice de rang $r \leq \min(m, n)$ représentant une image en niveaux de gris. Il existe deux matrices orthogonales $U \in R^{m\times m}$ et $V \in R^{n\times n}$, ainsi qu'une matrice diagonale $\Sigma \in R^{m\times n}$ telles que :

$$A = U\Sigma V^T = \sum_{i=1}^{r} \sigma_i u_i v_i^T \tag{1}$$

où :

- $U = [u_1, u_2, \ldots, u_m]$ contient les vecteurs singuliers à gauche (vecteurs propres de AA^T).
- $V = [v_1, v_2, \ldots, v_n]$ contient les vecteurs singuliers à droite (vecteurs propres de A^TA).

- $\Sigma = diag(\sigma_1, \sigma_2, \ldots, \sigma_r)$ contient les valeurs singulières ordonnées : $\sigma_1 \geq \sigma_2 \geq \ldots \geq \sigma_r > 0$.

2.2 Théorème d'Eckart-Young-Mirsky et Approximation de Rang k

Pour réduire la dimension et compresser l'image, on restreint la somme aux k premières valeurs singulières ($k < r$). La matrice tronquée A_k s'écrit :

$$A_k = \sum_{i=1}^{k} \sigma_i u_i v_i^T \tag{2}$$

Selon le théorème d'Eckart-Young, A_k est la meilleure approximation de rang k de la matrice A au sens de la norme de Frobenius $\| \cdot \|_F$. L'erreur relative d'approximation s'exprime directement par les valeurs singulières négligées :

$$\frac{\|A - A_k\|_F}{\|A\|_F} = \sqrt{\frac{\sum_{i=k+1}^{r} \sigma_i^2}{\sum_{i=1}^{r} \sigma_i^2}} \tag{3}$$

3 Analyse Numérique et Taux de Compression

Le stockage complet de l'image A nécessite $m \times n$ éléments. L'approximation de rang k ne requiert que la conservation des k premiers vecteurs de U, V et des k valeurs singulières, soit un total de $k(m+n+1)$ valeurs. Le taux de stockage mémoire relatif est donné par :

$$Tauxdedonnées = \frac{k(m+n+1)}{m \times n} \tag{4}$$

4 Résultats Expérimentaux

L'implémentation sous Python a été réalisée sur la matrice d'image `scipy.datasets.face(gray=True)` de dimension 768×1024 ($r_{max} = 768$). Le Tableau 1 résume la baisse d'erreur relative de Frobenius en fonction du rang k.

Table 1: Erreur relative et restitution selon le rang k

Rang k	**Éléments stockés**	**Erreur relative ($\|A - A_k\|_F / \|A\|_F$)**	**Qualité visuelle**
5	$8,965$	$\approx 18.2\%$	Silhouettes / Contour
20	$35,860$	$\approx 9.5\%$	Formes reconnaissables
50	$89,650$	$\approx 4.8\%$	Bonne visibilité
100	$179,300$	$\approx 2.3\%$	Quasi-identique à l'originale

La Figure **??** illustre la capacité de la SVD à capturer la majorité de l'information structurelle avec seulement $k = 50$ ou 100 valeurs singulières, générant une décroissance exponentielle rapide de l'erreur d'approximation.

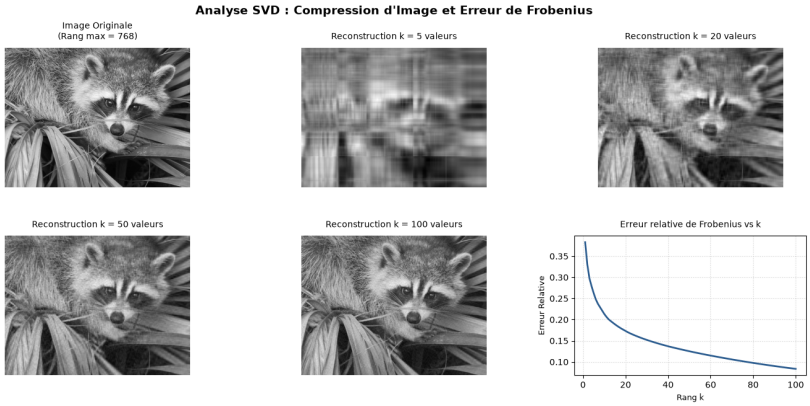


Figure 1: Résultats de la reconstruction par SVD pour différentes valeurs de k et courbe d'erreur relative de Frobenius.

5 Conclusion

Ce projet démontre l'efficacité de la Décomposition en Valeurs Singulières pour la réduction de dimensionnalité. En plus du traitement d'images, la SVD constitue le socle mathématique de l'Analyse en Composantes Principales (ACP), largement utilisée en finance quantitative pour la réduction des facteurs de risque et la déconvolution des matrices de covariance.